

祖龙 (ZULONG) 项目申报书

文档性质: OPC 超级个体专项申报版 申报方向: AI 智能体记忆系统 + 具身机器人认知 OS 版本: v1.0 日期: 2026-04-29 技术附件: 《祖龙 (ZULONG) 技术规格说明书 (TSD) v2.6 - 项目申报专用版》

项目速览

一句话定位: 祖龙 (ZULONG) 是一套面向 AI 智能体和机器人的认知操作系统，解决AGENT记得少，记不准，记不久，无法跨会话记忆的问题和实时对话打断。通过"图记忆 + 任务编排 + 代码锚点"三角闭环架构，为Agent 提供"理解 - 规划 - 执行 - 学习"的完整认知循环能力。

指标	数据
核心代码量	30,000+ 行, 49+ 核心文件
开发模式	一人独立完成全部架构设计与代码实现 (OPC 模式)
迭代轮次	26 个版本迭代 (v1.6 -> v2.6), 1个月+ 持续开发
生产级模块	3 个核心模块达到生产级成熟度
竞品对标	全球范围 8 个深度竞品调研, 三角闭环架构全市场唯一
产品落地	记忆 MCP 插件: <code>pip install zulong-memory</code> , 面向 \$50B+ 编程 Agent 市场

一、项目背景与市场机遇

1.1 AI Agent 市场进入生产级阶段

2026 年 AI Agent 市场正从 "Demo 级演示" 进入 "生产级部署" 阶段。三个细分赛道与本项目直接相关:

细分赛道	市场规模 (2026E)	成熟度	祖龙切入点
Agent 记忆层	早期 (<\$500M)	萌芽期	主攻方向 -- 图记忆 MCP 服务
Agent 编排框架	~\$5B	成长期	差异化方向 -- 深度可靠性保障
具身机器人 AI	~\$20B	导入期	长线方向 -- 认知大脑后端

1.2 四大产业趋势

趋势一: 记忆成为 Agent 核心竞争力

Harrison Chase (LangChain 创始人, 2026): "记忆是长周期的 Context Engineering, 能构筑深厚壁垒。" Anthropic 2026 趋势报告: "In 2026, agents will be able to work for days at a time." 长程 Agent 的核心依赖是持久记忆系统。

趋势二: 端侧 AI 崛起

4B-8B 参数模型在端侧设备上运行成为趋势, 但所有主流框架假设 70B+ 云端模型, 无人為小模型提供可靠运行时。这是一个被忽视的蓝海市场。

趋势三: MCP 协议标准化

Anthropic 主导的 MCP 协议成为 Agent 工具接入的事实标准。MCP 生态 2026 年将爆发，但"记忆"和"任务编排"层的 MCP 服务供给严重不足。

趋势四: 具身 AI 认知层缺位

ROS 2 解决通信、NVIDIA Isaac 解决仿真与运动控制，但"机器人如何理解、记忆、规划"的认知层，目前无标准产品。AEROS 论文 (arXiv:2604.07039, 2025.4) 提出 Single-Agent Robot Principle，学术上刚形成共识。

二、核心痛点与市场需求

2.1 三大未被满足的核心需求

需求	痛点描述	满足度
跨会话长期记忆	每次新会话从零开始，不记得项目架构、技术选型、踩过的坑	低
小模型可靠执行	端侧/低成本场景需要 4B-8B 模型可靠完成任务，所有框架假设大模型	空白
机器人认知能力	机器人需要理解、记忆、规划能力，不仅是运动控制	低

2.2 现有方案缺陷

当前 MCP 记忆市场已有早期产品 (Mem0 OpenMemory / Zep Graphiti MCP / Eve Memory 等)，但均存在共性缺陷:

缺陷维度	现有方案	祖龙解决方案
记忆结构	扁平向量 + KV 存储	异构图 (9 种节点 + 7 种边)
检索方式	语义相似度搜索 (top-k 全量注入)	BFS 扩散激活 + FAISS 双路径 (认知级过滤)
衰减/遗忘	无 (无限累积) 或 LLM 去重	艾宾浩斯曲线 + 6 级重要度分层
关联发现	无 / LLM 显式抽取 (高成本)	赫布学习自动发现 (零 LLM 成本)
任务编排	无	TaskGraph 递归有向图
上下文管理	全量注入 (挤占推理空间)	三模式注意力窗口 + graph_boost

2.3 目标用户群

用户群体	场景	优先级
编程开发者	使用 Claude Code/Cursor/Qoder 等编程 Agent，需跨会话记忆	最高 (快速落地)
AI 应用开发者	构建 LLM 应用产品，需深度可靠性保障	高
机器人厂商/研究者	为机器人赋予认知能力，需认知大脑集成	中 (长线方向)

三、产品定位与战略布局

3.1 双轨并行策略

产品线	定位	目标	优先级
祖龙记忆 MCP	编程 Agent 的跨会话记忆插件	快速落地、验证市场、拉取投资	P0
祖龙主线	机器人/LLM 认知操作系统	长期独立研发，完整 AI 系统	P1

双向反哺机制:

- MCP 产品验证记忆架构 -> 反馈改进主线记忆引擎
- 主线的图记忆研究成果 -> 增强 MCP 产品的技术深度
- MCP 产品的收入 -> 支撑主线长期研发

3.2 快速落地: 记忆 MCP 服务

产品定位: 祖龙记忆 MCP 不是编程 Agent，而是编程 Agent 的记忆层。

- 不跑 LLM、不做推理 -- 纯状态管理服务
- 不替代任何编程 Agent -- 增强它们
- 编程 Agent 自己的模型同时作为祖龙的 LLM -- 深度融合

用户体验: `pip install zulong-memory` -> `zulong-memory init` -> 配置 MCP 连接 -> 正常使用编程 Agent

MVP 工具集 (7 个):

类别	工具名称	功能
记忆工具	<code>zulong_memory_search</code>	图记忆语义检索
记忆工具	<code>zulong_memory_write</code>	写入新记忆节点
记忆工具	<code>zulong_memory_list</code>	列出记忆概览
任务工具	<code>zulong_task_view</code>	查看任务图状态
任务工具	<code>zulong_task_create</code>	创建任务节点
任务工具	<code>zulong_task_update</code>	更新任务状态
上下文工具	<code>zulong_context_inject</code>	智能上下文注入

3.3 长线方向: 机器人认知大脑

核心理念: 祖龙不做运动控制，而是作为"后端认知大脑"赋予机器人理解、记忆、规划能力，通过 L1 层桥接 ROS 2 / 厂商 SDK 等机器人原生系统。

架构模型:

层级	组件	功能
上层	祖龙 L2 认知大脑	FC Loop + TaskGraph + MemoryGraph
中层	祖龙 L1 调度中枢 + 感知插件	事件路由 + 中断仲裁 + 标准化感知接口 (IL1Module)
底层	机器人原生系统	ROS 2 / MoveIt2 / Nav2 / 厂商 SDK

学术验证: AEROS 论文 (arXiv:2604.07039) 提出的 Single-Agent Robot Principle 与祖龙架构完全一致 -- Agent 不直接操作执行器，而是通过专用运行时层路由命令。

四、核心竞争优势

4.1 唯一的"三角闭环"架构 -- Memory x TaskGraph x Code Anchor

能力维度	祖龙	最接近竞品	差距
记忆图谱	9 节点 + 7 边异构图	Shodh-Memory 5 节点 / MemCP 4 类型	祖龙节点/边种类最丰富
任务编排	TaskGraph 递归 DAG + 可视化	LangGraph (DAG)	祖龙与记忆图原生集成
代码锚点	Code Anchor 双向追踪 (代码<->任务<->记忆)	无竞品实现	市场唯一
三者联动	记忆指导任务分解 -> 任务驱动代码修改 -> 代码变更回写记忆	无竞品实现闭环	市场唯一

意义: 任何单一竞品只覆盖其中一个维度。祖龙的三角闭环使 Agent 在长程任务中具备"理解 -> 规划 -> 执行 -> 学习"的完整认知循环。

4.2 认知科学驱动的记忆系统

祖龙是市场上唯一将认知科学理论系统性工程化的 Agent 记忆系统:

特性	祖龙	Mem0	Zep	Shodh-Memory
图结构	9 节点 + 7 边异构	扁平 KV	实体-关系图	5 节点
三维标签	温度/重要性/时间域	无	无	无
Hebbian 学习	渐近饱和 + 自动创建边	无	无	有 (简单)
Ebbinghaus 衰减	6 级重要度半衰期 + LLM 审查	无	双时间戳失效	混合指数+幂律
扩散激活	BFS + FAISS 双路并行	无	无	spreading activation
LLM 摄入成本	0-1 次/轮	1-2 次	6-7+ 次	1-2 次

祖龙独有: 三维标签体系 (温度/重要性/时间域) 在所有调研产品中无人实现, 使记忆检索可同时按"活跃度""重要程度""时间范围"三个轴精准过滤。

4.3 极致的小模型可靠性保障

祖龙是市场上唯一面向 4B-8B 小模型设计完整可靠性方案的系统:

保障层	机制	说明
第 1 层	5 层防护链	格式修复 -> 安全过滤 -> 幻觉检测 -> 一致性校验 -> 降级回退
第 2 层	CB 6 信号熔断	连续失败/超时/资源耗尽/异常率/依赖故障/手动触发
第 3 层	专家热切换 (<10ms)	7 专家类型 (通用/逻辑/创意/导航/操控/视觉/TTS), LRU 淘汰
补充	双脑容器	左脑 temp=0.3 逻辑推理 / 右脑 temp=0.8 创意生成
补充	小模型兜底	RTX 3060 6GB 即可运行, 4bit 量化
补充	两阶段意图分类	粗分类 -> 细分类, 减少大模型调用

补充	双实例中断	高优先级任务安全中断低优先级执行
补充	多级重试与降级	自动重试 -> 模型降级 -> 功能降级 -> 安全停止

对比: AutoGen/CrewAI/LangGraph 均假设底层 LLM 调用可靠，无此类补偿设计。

4.4 三层协同上下文管理

竞品框架 (LangGraph/AutoGen/CrewAI) 无上下文预算管理机制。祖龙通过三层协同实现同等上下文窗口下 **3-5 倍于竞品的有效信息密度**:

层级	机制	上下文空间贡献
图记忆层	BFS 扩散选择性激活 + Temperature 冷热路由	认知级过滤，上下文占用降低 60-80%
注意力窗口	三模式 (GLOBAL/FOCUS/SINGLE_CHAIN) + graph_boost	预算级裁剪，淘汰低权重历史
L3 专家分流	TTS/运动控制/深度推理独立处理	领域级分流，减少 30-50% 专业上下文

4.5 竞争力量化评分

能力维度	祖龙	市场最佳	判断
异构图记忆	9/10	8/10 (Zep)	祖龙领先
FC 循环防护	10/10	5/10 (LangGraph)	祖龙遥遥领先
小模型补偿	10/10	0/10	蓝海领域
上下文管理	9/10	0/10	祖龙领先
对话打断/恢复	9/10	0/10	祖龙领先
多 Agent 协作	6/10	9/10 (AutoGen)	有差距
生态/社区	1/10	10/10 (ROS 2)	严重落后
产品化/商业	2/10	8/10 (Mem0/Zep)	严重落后

五、技术实力证明

5.1 代码实现（非 PPT）

指标	数据
核心代码量	30,000+ 行, 49+ 核心文件
生产级模块	图记忆引擎、任务编排循环、死循环检测 -- 3 个模块达生产级
版本迭代	v1.6 -> v2.6, 26 个版本, 2 年+ 持续开发
独创技术	生物启发式图记忆 (赫布学习 + 艾宾浩斯衰减)、5 层防护链、代码锚点系统
竞品唯一性	全球无同类产品实现"记忆 <-> 代码"双向追踪

5.2 四层自适应架构

系统采用 L0-L3 四层解耦架构，各层可独立替换:

层级	职责	成熟度
L0 执行层	硬件驱动，原子动作执行	生产级
L1 感知层	调度中枢 (L1-B) + 感知插件 (L1-A/C/D/E)，标准化 IL1Module 接口	生产级
L2 认知层	LLM 推理引擎，FC 循环，双实例热备	生产级
L3 专家池	多领域专家技能，LRU 调度	可用级
图记忆层	MemoryGraph + TaskGraph 双图联动	生产级

5.3 核心技术清单

技术	实现状态	说明
MemoryGraph 统一图	已实现	NetworkX DiGraph, 9 种节点 + 7 种边
BFS 扩散激活算法	已实现	可配置跳数, 衰减系数, 双向传播
赫布学习引擎	已实现	渐近饱和公式, 自动创建 ASSOCIATION 边
艾宾浩斯衰减修剪	已实现	6 级重要度半衰期 (TRIVIAL 6h ~ MUST_REMEMBER 无穷)
5 层防护链	已实现	CB 强制收敛/RuleGuardian/InfoGap/AutoMark/Backfill
Circuit Breaker 6 信号	已实现	重复/循环/增益递减/上下文压力/时间/无进度
4B 模型 8 种补偿	已实现	全市场唯一
KV Cache 热切换	已实现	双实例热备, <10ms 切换延迟
TaskGraph 递归 DAG	已实现	无限深度递归树 + 依赖图 + 状态机
代码锚点 (Code Anchor)	已实现	双向追踪 + Git Observer 自动更新
三层注意力机制	已实现	L0 采集 -> L1 静默注意 -> L2 交互注意
四层级联视觉	已实现	YOLO -> ROI 光流 -> MobileNet-TSM -> MediaPipe
L1 插件架构	已实现	IL1Module 标准接口 + PluginManager 热插拔
经验自进化系统	已实现	文件再修改/对话结束/Git commit 三大触发点

六、商业模式与市场空间

6.1 商业化路径

路径	可行性	市场空间	建议优先级
记忆 MCP SaaS	高	中	最高 -- 图记忆+任务编排组合差异化
边缘 Agent 运行时	中	大	高 -- 面向 4B-8B 端侧部署
具身 AI 认知大脑	中	大	中 -- 需实现 ROS 2 适配器

6.2 变现模型 (记忆 MCP 方向)

层级	功能	定价
免费版	本地存储、单项目、基础记忆	\$0
Pro 版	云同步、多项目、高级搜索、经验系统	\$9-19/月
Team 版	团队记忆共享、权限管理、审计日志	\$29-49/人/月
Enterprise	私有部署、自定义集成、SLA	定制

6.3 市场机会

- 编程 Agent 市场 2026 年预计 **\$50B+**
- 所有主流编程 Agent (Claude Code/Cursor/Qoder/Windsurf) 都缺少跨会话记忆 (公认痛点)
- MCP 协议成为行业标准, 记忆类 MCP 服务供给严重不足

6.4 商业壁垒

- 数据网络效应:** 记忆积累越多, 价值越高, 用户越难迁走
- 协议先发:** 率先覆盖主流编程 Agent 的 MCP 适配
- 技术护城河:** 三角闭环 (Memory + TaskGraph + Code Anchor) 的集成需要大量架构设计, 竞品短期内难以复制

七、竞争窗口与风险分析

7.1 竞争窗口

- 差异化窗口期: 3-6 个月** -- 第三代记忆产品 (MemCP/Shodh-Memory/ClawMem) 正在追赶
- 三角闭环护城河:** Memory + TaskGraph + Code Anchor 的深度集成, 当前无竞品同时实现
- 具身 AI 认知层空白:** Tesla/Boston Dynamics/宇树的运动控制成熟度越高, 对认知层的需求越迫切

7.2 低概率被追上的核心壁垒

壁垒	理由
赫布学习 + 艾宾浩斯 + 三维标签	认知科学交叉领域深度工程, 头部企业路线是"让模型更强", 不走此路线
5 层防护链 + CB + 4B 补偿	只有真实部署小模型才能发现这些问题, 头部企业用 70B+ 不会遇到
TaskGraph + MemoryGraph 深度耦合	双向同步 (状态->激活值、级联、地址继承) 是独有的工程积累
三层协同上下文管理	从检索到执行的全链路上下文管控, 竞品均为单一注入模式

7.3 风险提示

风险	影响	应对
头部企业升级 Memory 为图结构	记忆优势被削弱	加速 MCP 产品化, 建立用户基础
LangGraph 原生集成 TaskGraph + 记忆	编排优势被削弱	深化三角闭环耦合, 做好差异化
MCP 生态竞品快速追赶	差异化窗口关闭	3-6 个月内完成 MVP 发布

八、OPC 超级个体模式

8.1 模式说明

本项目是 AI 时代"超级个体" (OPC, One Person Company) 模式的真实案例。创始人从设计师背景出发，独立完成了从架构设计到代码实现的全部工作，相当于传统 5-8 人技术团队的产出。

8.2 OPC 模式核心价值

维度	传统团队	OPC 模式
决策速度	需协调 5-8 人	个人即刻决策
架构一致性	多人协作需对齐	天然一致 (一人全栈)
沟通成本	高 (会议/文档/对齐)	零
迭代速度	周级	日级
AI 工具利用	部分使用	深度协作 (AI 作为核心生产力工具)

8.3 技术产出

产出	数据
核心代码	30,000+ 行 Python
核心文件	49+ 个
版本迭代	26 个版本 (2 年+)
技术文档	TSD v2.6 (140,000+ 字)
市场调研	8 个竞品深度对标 + 5 个产业平台分析
独创技术	5 项 (图记忆/防护链/代码锚点/三层注意力/四层视觉)

九、执行路径

9.1 最紧迫行动项

优先级	行动项	说明
P0	MCP 产品化	将 MemoryGraph 抽取为独立包，通过 MCP Server 对外暴露
P0	基准测试	跑通 DMR / LongMemEval，建立量化数据
P1	双实例 L2 打断 Demo	所有竞品都没有的体验差异
P1	Edge Agent Runtime	5 层防护链 + CB + 4B 补偿抽取为独立运行时
P2	L1 ROS 2 适配器	为具身 AI 方向铺路

9.2 三阶段执行路径

阶段	核心任务
Phase 1: 快速验证	抽取 zulong-memory-core 独立包; 实现 MCP Server (7 个核心工具); Claude Code + Qoder 规则模板; 基准测试 (DMR/LongMemEval); PyPI 发布 + 社区推广
Phase 2: 差异化增强	Git Observer 被动记忆采集; 代码锚点系统; 经验系统 + 图操作工具; 双实例 L2 打断 Demo; Edge Agent Runtime 原型
Phase 3: 全面铺开	云同步 + 团队协作; Web Dashboard; L1 ROS 2 外部适配器; 开源社区运营; 投资材料准备

附录

附录 A: 竞品调研范围

本申报书基于 6 个 Agent 记忆/编排竞品 (Zep/Letta/Mem0/LangGraph/AutoGen/CrewAI) + 4 个第三代记忆产品 (MemCP/ClawMem/Shodh-Memory/AgentMemory) + 5 个具身平台 (Tesla Optimus/Boston Dynamics/宇树/ROS 2/NVIDIA Isaac) + 头部企业路线图的深度调研结果。

详细对标数据参见《祖龙市场调研与竞品分析 v2.0》。

附录 B: 技术附件

《祖龙 (ZULONG) 技术规格说明书 (TSD) v2.6 - 项目申报专用版》 -- 完整覆盖系统全部技术模块的详细规格文档。

附录 C: 核心引用

- Harrison Chase, "Memory as Context Engineering", LangChain Blog, 2026
- Anthropic, "In 2026, agents will be able to work for days at a time", 2026 Trends Report
- Addy Osmani, "5 Design Patterns for Long-running Agents", 2026.4.28
- AEROS: "Single-Agent Robot Principle", arXiv:2604.07039, 2025.4